

## Practica Profesionalizante 2- Evidencia 2

### Alumnos:

Almada, Sergio Daniel Beltramone, Mateo Guzmán, Nahir Dayana Navarro, Paola Giselle Galeano, Gerardo Agustín Gesto, Giuliana Sofía

> Link al Colab Link al Github

# Informe de Análisis de Fairness por Neighborhood

# **Resumen Ejecutivo**

Este informe presenta un análisis de equidad algorítmica enfocado en la variable **Neighborhood** (barrio) para el dataset de precios de viviendas. El análisis revela **disparidades significativas** entre barrios que pueden introducir sesgos en modelos predictivos de precios inmobiliarios.

## **Hallazgos Principales**

- 25 barrios analizados con un factor de disparidad de 3.6x entre el barrio más caro y el más económico
- **36% de los barrios** presenta alta volatilidad de precios (CV > 0.3)
- 2 barrios críticos con representación insuficiente (< 10 muestras)
- Distribución relativamente equilibrada por categorías de precio

## 1. Análisis de Representación

### 1.1 Distribución por Categorías de Precio

Categoría	Cantidad de Casas	Porcentaje	Status
Bajo	667 casas	45.7%	☑ Bien representada
Medio	515 casas	35.3%	☑ Bien representada
Alto	278 casas	19.0%	♣ Sub-representada

**Interpretación:** La categoría de barrios de precio alto está sub-representada, lo que puede sesgar el modelo hacia predicciones menos precisas para viviendas de lujo.

## 1.2 Barrios con Representación Crítica

Barrio	Número de Muestras	Riesgo
Blueste	2 casas	Crítico
NPkVill	9 casas	O Alto

**Implicaciones:** Estos barrios tienen muestras insuficientes para entrenar modelos robustos, lo que puede resultar en:

- Predicciones poco confiables
- · Alta varianza en las estimaciones
- Potencial discriminación algorítmica

## 2. Análisis de Disparidad de Precios

### 2.1 Métricas de Inequidad

• Rango de precios medianos: \$88,000 - \$315,000

• Factor de disparidad: 3.6x

• Barrio más caro: Precio mediano de \$315,000

• Barrio más económico: Precio mediano de \$88,000

### 2.2 Contexto de Disparidad

Un factor de disparidad de **3.6x** indica una **inequidad moderada-alta** en el mercado inmobiliario. Esto sugiere:

- Segmentación clara del mercado por ubicación
- Posibles barreras socioeconómicas de acceso
- Riesgo de perpetuar desigualdades existentes a través de algoritmos

### 3. Análisis de Volatilidad de Precios

## 3.1 Barrios con Alta Volatilidad (CV > 0.3)

Barrio	Coeficiente de Variación	Precio Mediano	Interpretación
StoneBr	0.364	\$278,000	Mercado muy heterogéneo
NoRidge	0.362	\$301,500	Alta variabilidad premium
Crawfor	0.327	\$200,624	Gentrificación posible
NridgHt	0.305	\$315,000	Segmento de lujo diverso
Veenker	0.303	\$218,000	Transición de mercado

Total: 9 barrios (36% del total) con alta volatilidad

## 3.2 Barrios con Baja Volatilidad (CV < 0.15)

Barrio	Coeficiente de Variación	Precio Mediano	Interpretación
NPkVill	0.066	\$146,000	Mercado homogéneo*
Blueste	0.139	\$137,500	Precios consistentes*
BrDale	0.137	\$106,000	Segmento estable

<sup>\*</sup>Nota: Los primeros dos barrios tienen muestras muy pequeñas, por lo que la baja volatilidad puede ser artificial.

## 4. Identificación de Riesgos de Sesgo

#### 4.1 Indicadores Detectados

## Sesgo de Representación

- Barrios de lujo sub-representados (19% vs 45.7% de barrios económicos)
- Dos barrios con muestras críticamente pequeñas

## Sesgo de Volatilidad

- 36% de barrios con alta volatilidad puede llevar a predicciones inconsistentes
- Concentración de volatilidad en segmentos de precio medio-alto

## Riesgo de Amplificación

- · Los algoritmos pueden amplificar las disparidades existentes
- Predicciones menos confiables para grupos minoritarios

## 4.2 Tipos de Fairness Comprometidos

Tipo de Fairness	Status	Descripción
Representational Fairness	Comprometido	Sub-representación de barrios específicos
Allocative Fairness	En riesgo	Disparidad 3.6x puede perpetuarse
Quality of Service	En riesgo	Menor precisión para grupos pequeños

## 5. Recomendaciones Estratégicas

## **5.1 Acciones Inmediatas (Corto Plazo)**

### 1. Tratamiento de Muestras Pequeñas

- Agrupar Blueste y NPkVill con barrios similares
- Aplicar técnicas de oversampling sintético (SMOTE)
- Considerar modelos jerárquicos por región

#### 2. Estratificación del Modelo

- Entrenar modelos separados por categoría de precio
- Implementar ensemble weighted por representación
- Validación cruzada estratificada por barrio

#### 3. Monitoreo de Equidad

- Métricas de fairness por barrio en producción
- Alertas automáticas para disparidades > 4x

Dashboard de equidad para stakeholders

### 5.2 Estrategias de Mediano Plazo

#### 1. Recolección de Datos

- Enriquecer dataset con más muestras de barrios sub-representados
- Incorporar variables socioeconómicas contextuales
- Datos temporales para análisis de tendencias

#### 2. Técnicas Avanzadas de Fairness

- Implementar constraint-based fairness durante entrenamiento
- Post-processing para calibrar predicciones por grupo
- · Adversarial debiasing networks

#### 3. Validación Robusta

- Testing con datos externos por barrio
- Auditorías de equidad trimestrales
- Análisis de impacto diferencial

## **5.3 Consideraciones Éticas y Regulatorias**

### 1. Transparencia

- Documentar limitaciones por barrio
- Comunicar incertidumbre en predicciones
- Explicabilidad localizada por grupo

#### 2. Gobernanza

- Comité de ética para decisiones de fairness
- Políticas de uso responsable del modelo
- Protocolo de escalación para casos edge

### 6. Conclusiones

#### 6.1 Estado Actual

El análisis revela **desafíos moderados de fairness** en el dataset, con disparidades significativas pero manejables. La representación desigual y alta volatilidad en algunos barrios requieren **intervención proactiva** para evitar discriminación algorítmica.

### 6.2 Viabilidad del Proyecto

Viable con mitigaciones: El proyecto puede proceder implementando las recomendaciones de fairness propuestas.

### **6.3 Próximos Pasos Prioritarios**

- 1. Implementar agrupación de barrios con muestra pequeña
- 2. Estratificar validación por categoría de precio
- 3. Establecer métricas de monitoreo continuo
- 4. Desarrollar pipeline de fairness automatizado

### **Anexos**

### A.1 Métricas Técnicas Detalladas

- Coeficiente de Gini por barrio: Pendiente de cálculo
- Índice de Theil: Análisis de segregación espacial
- Disparate Impact Ratio: Por implementar post-predicciones

## A.2 Referencias Metodológicas

- IEEE Standards for Algorithmic Bias Assessment
- Google's What-If Tool para análisis de fairness
- IBM AI Fairness 360 toolkit

Informe generado el: Mayo 2025

Autor: Análisis Automatizado de Fairness

Dataset: House Prices - Advanced Regression Techniques